



UNIVERSIDADE FEDERAL DE SANTA CATARINA
CENTRO TECNOLÓGICO
DEPARTAMENTO DE INFORMÁTICA E ESTATÍSTICA
CURSO DE GRADUAÇÃO EM CIÊNCIAS DA COMPUTAÇÃO
PROBABILIDADE E ESTATÍSTICA (INE5405)

Leonardo de Sousa Marques
Rafael Veronezi Ribeiro
Ruan Alboni Ferreira
Thayse Estevo Teixeira

**Inferência Estatística de Dados do Exame Nacional de Desempenho dos Estudantes
(ENADE)**

Florianópolis
2025

1 Introdução

O Exame Nacional de Desempenho dos Estudantes (ENADE) foi instituído em 2004 pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) com o objetivo de avaliar o desempenho dos concluintes de cursos de graduação no Brasil. A cada ciclo trienal, determinados cursos em todo o país realizam a prova, que avalia o conhecimento dos estudantes sobre os conteúdos programáticos definidos nas diretrizes curriculares de cada curso (SEAVI, 2020).

Nesse contexto, o ENADE fornece um conjunto de métricas destinadas à avaliação dos cursos e das instituições de ensino superior, tais como o Conceito Enade (CE), o Conceito Preliminar de Curso (CPC), o Indicador de Diferença entre os Desempenhos Observados e Esperado (IDD) e o Índice Geral de Cursos (IGC). Esses indicadores, juntamente com as variáveis Categoria Administrativa e Modalidade de Ensino dos cursos avaliados, serão detalhados na seção de Materiais e Métodos.

O presente trabalho dá continuidade à análise exploratória realizada no Trabalho 1 da disciplina, ampliando o estudo por meio da aplicação de técnicas de inferência estatística – a partir dos dados de uma amostra, criamos testes de hipóteses para realizar conclusões e fazer generalizações sobre a população. Assim como na análise anterior, a população considerada corresponde aos cursos do estado de Santa Catarina. A partir desse conjunto de dados, será selecionada uma amostra aleatória, permitindo a realização de inferências estatísticas sobre a população com base nos resultados obtidos anteriormente, apresentados na Tabela 1.

A partir dos indicadores apresentados pelo ENADE, serão formuladas e testadas hipóteses relacionadas às médias, proporções, correlações e regressões, com o objetivo de aprofundar a compreensão acerca das variáveis quantitativas e qualitativas previamente examinadas.

Table 1: Estatísticas Descritivas dos Indicadores Contínuos (SC)

Indicador	Média	Mediana	Desvio Padrão	Variância	CV (%)	Mínimo	Máximo	Amplitude
Conceito ENADE (Contínuo)	2.478	2.488	0.971	0.943	39.196	0	4.972	4.972
IDD (Contínuo)	2.667	2.631	0.983	0.965	36.838	0	5	5
CPC (Contínuo)	2.885	2.857	0.636	0.404	22.029	0.977	4.603	3.626
IGC (Contínuo)	2.703	2.726	0.565	0.319	20.909	0.926	4.416	3.49

1.1 Objetivos

O objetivo principal do trabalho é tomar os indicadores apresentados anteriormente e que também foram utilizados no trabalho anterior e testar hipóteses levantadas sobre eles, sendo essas hipóteses aplicadas sobre a média e proporção dos dados de indicadores, além de hipóteses sobre a correlação e regressão entre duas dessas variáveis.

Com base nos dados dos indicadores, foram definidas as hipóteses a serem analisadas no presente trabalho:

1. Hipótese sobre a média:

H_0 : A média do CPC em cursos com ensino presencial em Santa Catarina é igual a média do CPC em cursos com ensino a distância.

2. Hipótese sobre a proporção:

H_0 : A proporção de instituições federais em Santa Catarina é de 25%.

3. Hipótese sobre a Correlação:

H_0 : Não há correlação entre o IDD e o Conceito Enade.

4. Hipóteses sobre a Regressão:

H_0 : O IDD não tem influência significativa sobre o Conceito Enade.

2 Materiais e Métodos

Nesta seção são apresentadas as variáveis quantitativas e qualitativas selecionadas para as análises estatísticas, as quais foram previamente exploradas no trabalho anterior e agora serão utilizadas na etapa de inferência estatística. A base de dados considerada compreende os cursos participantes do ENADE no ciclo trienal de 2021 a 2023, pertencentes ao estado de Santa Catarina, que constitui a população de interesse deste estudo.

Para a realização das inferências estatísticas, será determinado o tamanho de amostra necessário para cada tipo de variável, conforme as expressões apresentadas nas Equações 1a e 1b, aplicadas respectivamente às variáveis qualitativas e quantitativas:

$$\left. \begin{array}{l} (a) \quad n_0 = \frac{z^2 \cdot p \cdot (1-p)}{d^2} \\ (b) \quad n_0 = \frac{z^2 \cdot \sigma^2}{d^2} \end{array} \right\} \quad n = \frac{n_0}{1 + \frac{n_0}{N}} \quad (1)$$

Nas equações, n_0 representa o tamanho amostral inicial e n o tamanho amostral corrigido para populações finitas. O parâmetro z corresponde ao valor crítico da distribuição normal padrão associado ao nível de confiança adotado. Para obtermos um nível de confiança de 95%, iremos considerar $z = 1,96$. A variância populacional σ^2 é conhecida através da Tabela 1. O parâmetro p indica a proporção esperada de ocorrência de um determinado evento. Para nossa amostragem, consideraremos $p = 0,5$, a fim de maximizar a variância $p \cdot (1 - p)$. Já a variável d expressa o erro amostral tolerável, frequentemente fixado em 5%. E, por fim, N representa o tamanho da população.

2.1 Variáveis Quantitativas

1. Conceito Enade Contínuo (CE) - Variável Quantitativa Contínua

O Conceito Enade (CE) foi uma variável escolhida por avaliar o desempenho dos cursos de uma instituição de ensino. Sua métrica é baseada nos resultados obtidos por seus estudantes no Enade em relação ao desempenho geral da respectiva área acadêmica em todo o território nacional. Para fins de cálculo, um curso tem que ter pelo menos 2 participantes com resultados válidos no exame para gerar o Conceito Enade, um valor entre 0 e 5. (INEP, 2024b).

Conforme do anexo A, que sintetiza as fórmulas supracitadas, o tamanho da amostra aleatória para essa variável será $n = 699$.

2. Indicador de Diferença entre os Desempenhos Observados e Esperado Contínuo (IDD) - Variável Quantitativa Contínua:

O IDD foi escolhido por avaliar o quanto um curso de graduação impactou no desenvolvimento de seus estudantes. Ele leva em conta o desempenho dos estudantes no Enade, sua nota de ingresso no ensino superior, a qualidade do curso, entre outras medidas de desempenho, para então comparar o resultado aos dos demais cursos do país. Tudo isso é então compactado em uma variável entre 0 e 5.

Conforme o script do anexo A, o tamanho da amostra aleatória para essa variável será $n = 707$.

3. Conceito Preliminar de Curso Contínuo (CPC) - Variável Contínua

Por outro lado, o CPC foi uma escolha por avaliar a qualidade dos cursos de graduação. As métricas levadas em conta para o seu cálculo são o desempenho dos estudantes no Enade; a contribuição do curso ao desenvolvimento do aluno (IDD); a titulação e regime de trabalho do corpo docente (Censo da Educação Superior); e a opinião dos estudantes sobre a didática, infraestrutura e oportunidades de evolução acadêmica e profissional que o curso proporciona (Questionário do Estudante) (INEP, 2024a). Essa medida é relativa ao resultado médio da área de avaliação em todo o país, gerando uma faixa contínua definida de 1 a 5.

Conforme o script do anexo A, o tamanho da amostra aleatória para essa variável será $n = 426$.

2.2 Variáveis Qualitativas

1. Categoria Administrativa - Variável Nominal

Categoria Administrativa aborda o órgão responsável por gerir a instituição de ensino de determinado curso, sendo as 7 categorias possíveis: Pública Municipal, Pública Estadual, Pública Federal, Comunitária/Confessional, Privada sem Fins Lucrativos, Privada com Fins Lucrativos e Especial. Sua escolha vem do interesse de comparar a presença e o desempenho das instituições públicas e privadas no exame. Conforme o script do anexo A, o tamanho da amostra aleatória para essa variável será $n = 150$.

2. Modalidade de Ensino - Variável Nominal

A Modalidade de Ensino representa como as aulas do curso são administradas aos estudantes, tendo 2 modalidades possíveis: Educação Presencial e Educação a Distância. Por ser um tema recente, essa variável foi incluída para analisar o impacto dessas modalidades no desempenho e qualidade das instituições. Conforme o script do anexo A, o tamanho da amostra aleatória para essa variável será $n = 300$.

2.2.1 Base de Dados

A base de dados escolhida para o trabalho foi a mesma já apresentada no primeiro trabalho: os dados do Conceito Enade de 2021, 2022 e 2023 disponível no site do ENADE em formato XLSX, contendo além do indicador de Conceito Enade, o CPC e o IDD.

Novamente, os dados foram tomados por um intervalo suficiente para abranger um ciclo trienal completo e filtrados com um script em Python, para formatação das tabelas e conversão do arquivo XLSX para CSV, e um script em R, para conter somente as entradas referentes ao estado de Santa Catarina.

3 Resultados e Discussões

Nesta seção iremos apresentar as análises estatísticas realizadas com base nas variáveis selecionadas na seção de Materiais e Métodos. Inicialmente, serão discutidas as estatísticas descritivas das variáveis quantitativas e qualitativas, seguido pelos testes de hipóteses levantados na seção de Objetivos.

3.1 Análise das Estatísticas Descritivas

Observando a base de dados selecionada e suas medições descritivas calculadas sobre as amostras feitas, é possível extrair algumas características das variáveis de interesse analisadas. As variáveis quantitativas, por exemplo, tem uma distribuição perceptivelmente semelhante à normal, com uma concentração de valores em torno da média e gradativa redução em direção às extremidades, porém cada uma possui suas particularidades.

O Conceito Enade, com média 2,4753 e mediana 2,4753, apresenta certa inclinação a ter valores na parte inferior do intervalo (abaixo de 2,5), com seu desvio padrão de 0,9464 indicando a presença de valores afastados da média influenciando no seu cálculo. O IDD, por sua vez, tem um comportamento semelhante, porém invertido, com média 2.6829, mediana 2.661 e desvio padrão 1.0202 indicando a sua inclinação à parte superior do intervalo.

O CPC possui uma leve inclinação para a parte de baixo do intervalo (menor que 3), com média 2.8335 e mediana 2.8249, e também concentra seus valores mais ao redor da média, como indicado por seu desvio padrão de 0.6381, indicando menos valores nas extremidades.

Essas inclinações, porém, são muito leves para terem uma influência significativa nos intervalos de confiança de $\gamma = 95\%$ para a média dessas variáveis, sendo que os de Conceito Enade (2.405, 2.5456) e IDD (2.6076, 2.7582) compartilham uma extensão semelhante aos de CPC (2.7727, 2.8942), mostrando um desempenho semelhante ao aproximar o valor estimado a partir de uma amostra de tamanho particular para cada variável, o que também influencia na melhora das estimativas por levar em conta parâmetros como a variância.

Já ao observarmos as variáveis qualitativas, a modalidade de ensino presencial domina fortemente sobre a educação a distância, com cerca de 77% dos cursos. Enquanto isso, as categorias administrativas públicas concentram por volta de 6,7% das instituições de ensino. Nessas variáveis é possível perceber que os intervalos de confiança de 95% para estimar suas proporções são mais extensos que os das quantitativas, sendo (72.5957, 82.071) para modalidade de ensino Presencial e (2.6748, 10.6585) para categorias administrativas Públicas, o que pode ter influência da maximização da amostra pelo valor de p .

O script R utilizado para calcular os intervalos pode ser observado no anexo B.

3.2 Testes de Hipótese e Resultados

3.2.1 Hipótese sobre a Média

O objetivo da análise foi comparar a média do Conceito Preliminar de Curso (CPC) entre cursos com Ensino Presencial e cursos com Ensino a Distância (EaD) em Santa Catarina. A variável utilizada foi o CPC contínuo, enquanto a modalidade de ensino identificou o tipo de curso. As hipóteses formuladas foram:

- Hipótese nula (H_0): A média do CPC em cursos com ensino presencial em Santa Catarina é igual a média do CPC em cursos com ensino a distância (i.e., $\mu_{\text{Presencial}} = \mu_{\text{EaD}}$).
- Hipótese alternativa (H_1): A média do CPC em cursos com ensino presencial em Santa Catarina é maior que a média do CPC em cursos com ensino a distância (i.e., $\mu_{\text{Presencial}} > \mu_{\text{EaD}}$).

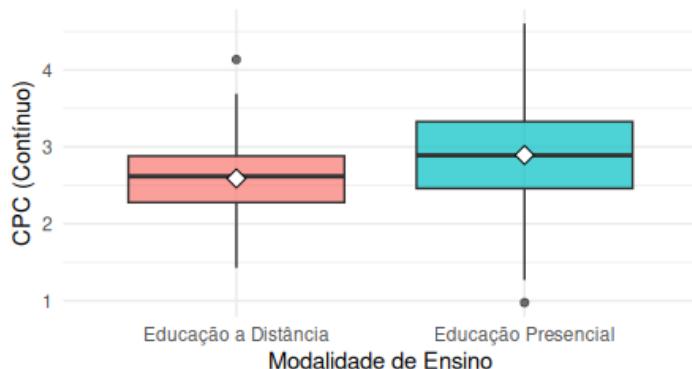
Para a análise, foi selecionada uma amostra aleatória de $n = 426$ cursos pertencentes às duas modalidades de interesse. Em seguida, foram extraídos os valores do CPC contínuo para cada

grupo, e aplicou-se o teste t de Welch, que não pressupõe igualdade de variâncias entre as amostras. Para isso, utilizou-se a função `t.test` do R, com o parâmetro `var.equal = FALSE`, nível de confiança de 95% (`conf.level = 0.95`) – assumindo um nível de significância de 5% – e `alternative = "greater"`, aplicando assim um teste unilateral à direita, pois o interesse era verificar se as médias dos cursos presenciais eram significativamente maiores. O *script* em R utilizado pode ser consultado no Anexo C.

Os resultados do teste indicaram $t = 4.6738$, graus de liberdade aproximados $df = 162.24$ e p -valor $= 3,09 \times 10^{-6}$. As médias amostrais foram 2,8942 para os cursos presenciais e 2,5898 para os cursos a distância. O intervalo de confiança unilateral de 95% para a diferença das médias foi $[0,1967, +\infty)$, o que significa que, com 95% de confiança, a média dos cursos presenciais excede a média dos cursos EaD em pelo menos aproximadamente 0,197 pontos. O gráfico da Figura 1 ilustra essa diferença, mostrando uma distribuição de CPCs mais elevada entre os cursos presenciais.

Diante desses resultados, **rejeita-se a hipótese nula**, pois o p -valor é muito inferior ao nível de significância de 5%, indicando que a diferença observada não é resultado do acaso. Conclui-se, portanto, que os cursos com ensino presencial apresentam CPC médio significativamente superior aos cursos com ensino a distância em Santa Catarina. Esse resultado sugere um desempenho médio mais elevado dos cursos presenciais segundo o indicador CPC.

Figure 1: Distribuição do Conceito Preliminar de Curso (CPC) por Modalidade de Ensino.



3.2.2 Hipótese sobre a Proporção

O objetivo desta análise foi verificar se a proporção de instituições federais em Santa Catarina é de 25%, conforme afirma a hipótese nula. A variável analisada foi a *categoria administrativa*, sendo considerado “sucesso” cada instituição classificada como Pública Federal. As hipóteses formuladas foram:

- Hipótese nula (H_0): A proporção de instituições federais em Santa Catarina é igual a 25% (i.e., $p = 0,25$).
- Hipótese alternativa (H_1): A proporção de instituições federais em Santa Catarina é diferente de 25% (i.e., $p \neq 0,25$).

Foi selecionada uma amostra aleatória simples de $n = 150$ instituições, das quais 8 foram identificadas como federais, resultando em uma proporção amostral de $\hat{p} = 0,0533$. Aplicou-se o teste de proporção única (`prop.test` no R) sem correção de continuidade e com nível de confiança de

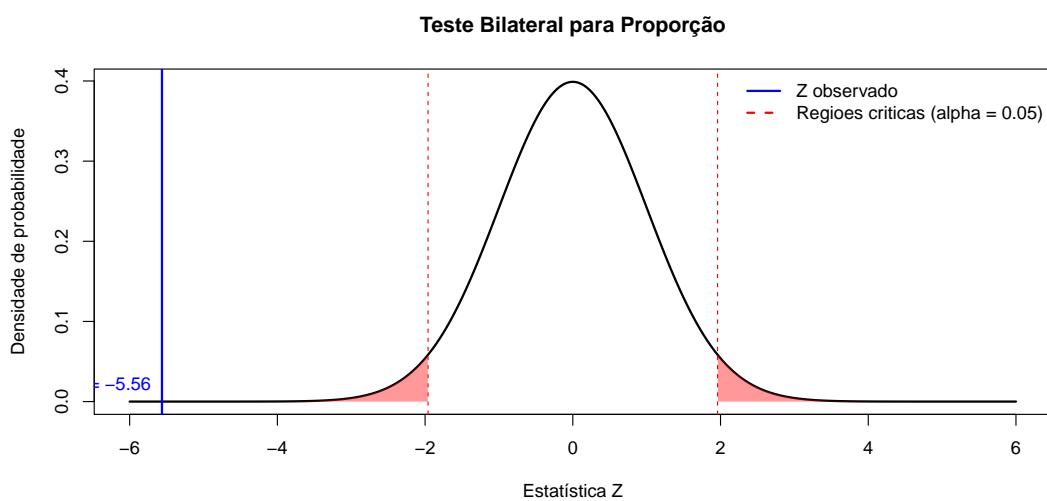
95%. O resultado indicou uma estatística qui-quadrado de $\chi^2 = 30,942$, equivalente a uma estatística padronizada $z = -5,56$, com p -valor de aproximadamente $2,66 \times 10^{-8}$. O intervalo de confiança de 95% para a proporção verdadeira foi estimado em $[0,027; 0,102]$.

Como o valor calculado de $z = -5,56$ está muito além do limite crítico bilateral de $z_{\text{crítico}} = \pm 1,96$, o ponto amostral situa-se claramente dentro da região de rejeição de H_0 . Essa relação pode ser visualizada na Figura 2, que mostra a distribuição normal padrão utilizada no teste, destacando as regiões críticas em vermelho e o valor observado de z em azul.

Dado que o p -valor é muito inferior ao nível de significância de 5%, **rejeita-se a hipótese nula**, concluindo que há evidências estatísticas de que a proporção de instituições federais em Santa Catarina é significativamente diferente de 25%. Observa-se, contudo, que a proporção observada (5,3%) é consideravelmente menor do que o valor hipotetizado, indicando uma sub-representação de instituições federais no estado. Em termos absolutos, a diferença entre a proporção observada e a esperada é de aproximadamente 0,20, ou seja, 19,7 pontos percentuais a menos.

Do ponto de vista prático, esse resultado sugere que a participação das instituições federais em Santa Catarina é inferior ao quanto esperado, o que pode refletir características estruturais do sistema de ensino superior estadual, marcado por forte presença de instituições privadas. Apesar da robustez estatística do teste, é importante considerar que o número de instituições federais observadas (apenas oito) é pequeno, o que pode reduzir a precisão das estimativas. Ainda assim, o intervalo de confiança exclui claramente o valor de 25%, reforçando a conclusão de que a proporção real é significativamente menor do que a hipotetizada.

Figure 2: Distribuição normal padrão do teste bilateral para a proporção de instituições federais ($p = 0,25$), destacando as regiões críticas ($\alpha = 0,05$) e o valor observado de $z = -5,56$.



3.2.3 Hipótese sobre a Correlação

- Hipótese nula (H_0): Não há correlação entre o IDD e o Conceito Enade
- Hipótese Alternativa (H_1): Existe correlação entre IDD e Conceito Enade

Para testar a Hipótese, primeiro foram tomadas as tabelas de IDD e CPC filtradas para o estado de Santa Catarina e criadas amostras independentes de semente = 123 e $n_{CE} = 698$ e $n_{IDD} = 706$.

As entradas foram associadas por meio do código da instituição, código do curso e ano em uma única tabela. Observou-se a presença de valores nulos, o que precisaram ser descartados já que não poderiam ser trabalhados no teste. Ao final, obteve-se uma tabela resultante dos valores de IDD e Conceito Enade relacionados para cada entrada, com um total de 388 entradas.

Realizando o teste de correlação de Pearson em R considerando 5% de significância (α), obteve-se os seguintes resultados: O Coeficiente de Correlação de Pearson (r) = 0.6945254 e o p-valor < 2.2×10^{-16} , com grau de liberdade de 386, valor de t calculado igual a 18.966 e intervalo de confiança de 95% igual a [0.6391626, 0.7427272].

Observou-se uma forte correlação positiva do coeficiente de correlação entre IDD e Conceito Enade ao estar próximo de $r = 1$, além de estar dentro do intervalo de confiança calculado. O p-valor se mostrou muito inferior ao nível de significância adotado (0.05), o que leva a rejeição da hipótese nula H_0 , ou seja, existe sim uma correlação significativa entre os valores dos indicadores de IDD e o Conceito Enade.

3.2.4 Hipótese sobre a Regressão

- Hipótese nula (H_0): O IDD não tem influência significativa sobre o Conceito Enade
- Hipótese Alternativa (H_1): O IDD tem influência significativa sobre o Conceito Enade

Para testar a hipótese, deve-se primeiro definir o modelo. O modelo de regressão linear ajustado é:

$$\text{Conceito Enade} = \beta_0 + \beta_1 \times (\text{IDD}) + \varepsilon$$

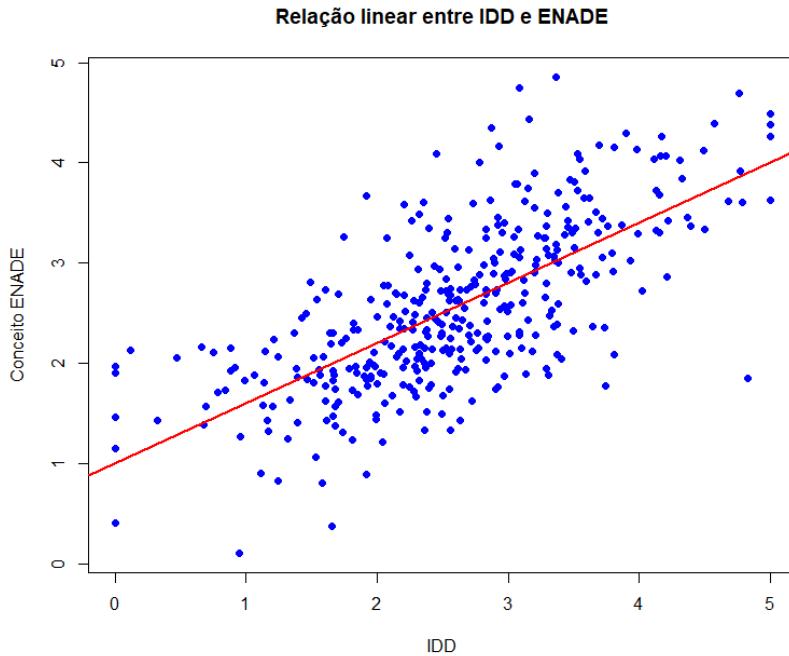
A hipótese nula será aceita caso o valor de β_1 seja igual a 0, ou seja, o valor do IDD não tem influência sobre o valor do Conceito Enade.

Utilizando o R, analisa-se a regressão e calcula-se os parâmetros utilizando os dados presentes na tabela resultante das amostras de IDD e Conceito Enade. Os resultados obtidos foram: intercepto ($\beta_0 = 1,00395$) e coeficiente angular ($\beta_1 = 0,59984$), erro padrão residual de 0,5829 e p-valor < $2,2 \times 10^{-16}$, com o coeficiente de determinação ajustado (R^2) igual a 0,481. Na Figura 2, observa-se o gráfico da relação entre as amostras de IDD e Conceito Enade.

Percebe-se que o coeficiente angular estimado é de 0,59984, valor significativamente diferente de 0 como propõe a hipótese, além disso, o p-valor calculado se manteve abaixo do nível de significância de 5%, portanto pode-se rejeitar a hipótese nula H_0 , concluindo que existe sim a influência de IDD sobre o valor do Conceito Enade.

Além disso, pode-se também tirar conclusões adicionais quanto ao coeficiente de determinação ajustado (0,481), indicando que aproximadamente 48,1% da variação no valor do Conceito Enade é explicada pelo IDD, sugerindo que cursos de valores maiores de IDD tendem a apresentar melhores valores do Conceito Enade.

Figure 3: Relação de regressão linear entre IDD e Conceito Enade.



4 Considerações Finais

Este trabalho avançou na análise exploratória dos dados do ENADE de Santa Catarina, aplicando métodos de inferência estatística para testar hipóteses formuladas sobre os indicadores de qualidade. O objetivo central foi validar suposições sobre a média do Conceito Preliminar de Curso (CPC) entre modalidades, a proporção de instituições federais e a relação de dependência entre o IDD e o Conceito Enade.

A aplicação dos testes revelou um cenário de resultados consistentes e estatisticamente significativos. Para a **Hipótese 1**, encontrou-se uma diferença estatisticamente robusta ($p\text{-valor} \approx 3,09 \times 10^{-6}$), confirmando que os cursos presenciais possuem, em média, um CPC superior aos da modalidade EaD em Santa Catarina. Já a **Hipótese 2** também levou à rejeição da hipótese nula, uma vez que o $p\text{-valor}$ obtido ($2,66 \times 10^{-8}$) é muito inferior ao nível de significância de 5%. Conclui-se, portanto, que a proporção de instituições federais em Santa Catarina é significativamente diferente de 25%, sendo, na verdade, consideravelmente menor (aproximadamente 5,3%). Esse resultado evidencia uma sub-representação das instituições federais no sistema de ensino superior do estado.

As análises de correlação e regressão (**Hipóteses 3 e 4**) reforçaram essas conclusões. Confirmou-se uma forte correlação positiva ($r \approx 0,694$) e uma influência estatisticamente significativa do IDD sobre o Conceito Enade. O coeficiente de determinação ajustado ($R^2 \approx 0,481$) indica que, embora o IDD seja um preditor relevante, ele explica menos da metade da variabilidade do Conceito Enade. Isso sugere que, apesar da significância estatística, o IDD não é o único fator determinante do desempenho, havendo influência de outras variáveis.

A constatação de que 51,9% da variação do Conceito Enade não é explicada pelo IDD aponta para a principal limitação deste modelo de regressão. Evidencia-se a necessidade de investigações futuras que incorporem outras variáveis (como as dimensões do próprio CPC: infraestrutura, qualificação docente e percepção discente) para construir um modelo preditivo mais abrangente e expli-

tivo.

Em síntese, este estudo reforça a natureza probabilística da inferência estatística. A rejeição das hipóteses nulas nas quatro análises realizadas não representa uma prova absoluta, mas sim fortes evidências contra H_0 , considerando o nível de significância de 5%. Os resultados obtidos devem ser interpretados como indícios de tendências consistentes, e não como relações determinísticas, destacando a importância de diferenciar significância estatística de causalidade e de relevância prática.

Referências

- INDICADORES DA EDUCAÇÃO SUPERIOR (CGGI/DAES/INEP), COORDENAÇÃO-GERAL DE. **Nota Técnica CEI/CGGI/DAES nº 19/2024 – Metodologia utilizada no cálculo do CPC referente ao ano de 2023.** [S.I.], 2024. Acessado em: 18 set. 2025. Disponível em: <https://download.inep.gov.br/educacao_superior/enade/notas_tecnicas/2023/nota_tecnica_n_19_2024_cei_cggi_daes_inep_metodologia_utilizada_no_calculo_do_cpc_referente_ao_ano_de_2023.pdf>.
- _____. **Nota Técnica CEI/CGGI/DAES nº 6/2024 – Metodologia utilizada no cálculo do Conceito Enade referente ao ano de 2023.** [S.I.], 2024. Acessado em: 18 set. 2025. Disponível em: <https://download.inep.gov.br/educacao_superior/enade/notas_tecnicas/2024/nota_tecnica_6_metodologia_calculo_conceito_enade_2023.pdf>.
- SECRETARIA ESPECIAL DE AVALIAÇÃO INSTITUCIONAL. **CONCEITO ENADE (CE) E CONCEITO PRELIMINAR DE CURSO (CPC) DOS CURSOS DE GRADUAÇÃO DO INMA.** [S.I.]: Universidade Federal de Mato Grosso do Sul (UFMS), 2020. Acessado em: 30 ago. 2025. Disponível em: <<https://seavi.ufms.br/files/2020/05/Relat%C3%B3rio-1-INMA-2020.pdf>>.

5 Anexos - Códigos Fonte

Todos os códigos, bases de dados, gráficos e tabelas podem ser observados em detalhes no repositório: <https://github.com/leonardosm14/ENADE-Estatisticas>

Listing 5.1: Anexo A: Amostragem

```
# --- Diretório ---
setwd("~/Documentos/UFSC/ENADE-Estatisticas")

# Carrega os dados filtrados de Santa Catarina
source(file = "src/script_sc.r")

# --- Parâmetros fixos padrão ---
z <- 1.96 # nível de confiança de 95%
d <- 0.05 # erro amostral tolerável (5%)

# --- Variáveis Quantitativas ---

# --- Funções ---
n0 <- function(variancia) {
  return((z^2 * variancia) / (d^2))
}

n <- function(n0, N) {
  return(n0 / (1 + (n0 / N)))
}

# --- 1. Conceito ENADE (Contínuo) ---
variancia_enade <- var(data_CPC_SC$conceito_enade_.continuo., na.rm = TRUE)
N_enade <- nrow(data_CPC_SC)

n0_enade <- n0(variancia_enade)
n_enade <- n(n0_enade, N_enade)

cat("\n--- Conceito ENADE (Contínuo) ---\n")
cat("Variância:", round(variancia_enade, 4), "\n")
cat("N:", N_enade, "\n")
cat("n0:", round(n0_enade, 2), "\n")
cat("n:", ceiling(n_enade), "\n")

# --- 2. IDD (Contínuo) ---
variancia_idd <- var(data_IDD_SC$idd_.continuo., na.rm = TRUE)
N_idd <- nrow(data_IDD_SC)
```

```

n0_idd <- n0(variancia_idd)
n_idd <- n(n0_idd, N_idd)

cat("\n--- IDD (Contínuo) ---\n")
cat("Variância:", round(variancia_idd, 4), "\n")
cat("N:", N_idd, "\n")
cat("n0:", round(n0_idd, 2), "\n")
cat("n:", ceiling(n_idd), "\n")

# --- 3. CPC (Contínuo) ---
variancia_cpc <- var(data_CPC_SC$cpc_.continuo., na.rm = TRUE)
N_cpc <- nrow(data_CPC_SC)

n0_cpc <- n0(variancia_cpc)
n_cpc <- n(n0_cpc, N_cpc)

cat("\n--- CPC (Contínuo) ---\n")
cat("Variância:", round(variancia_cpc, 4), "\n")
cat("N:", N_cpc, "\n")
cat("n0:", round(n0_cpc, 2), "\n")
cat("n:", ceiling(n_cpc), "\n")

# --- 4. IGC (Contínuo) ---
variancia_igc <- var(data_IGC_SC$igc_.continuo., na.rm = TRUE)
N_igc <- nrow(data_IGC_SC)

n0_igc <- n0(variancia_igc)
n_igc <- n(n0_igc, N_igc)

cat("\n--- IGC (Contínuo) ---\n")
cat("Variância:", round(variancia_igc, 4), "\n")
cat("N:", N_igc, "\n")
cat("n0:", round(n0_igc, 2), "\n")
cat("n:", ceiling(n_igc), "\n")

# --- Variáveis Qualitativas ---

p <- 0.5

# n0 é comum a todos

n0 <- z^2 * p * (1-p) / d^2

```

```

# --- 1. Categoria Administrativa ---
N_cat <- nrow(data_IGC_SC)
n_cat <- n(n0, N_cat)

cat("\n--- Categoria Administrativa ---\n")
cat("N:", N_cat, "\n")
cat("n:", ceiling(n_cat), "\n")

# --- 2. Modalidade de Ensino ---

N_mod <- nrow(data_CPC_SC) # total de cursos (cada curso tem uma modalidade)
n_mod <- n(n0, N_mod)

cat("\n--- Modalidade de Ensino ---\n")
cat("N:", N_mod, "\n")
cat("n:", ceiling(n_mod), "\n")

```

Listing 5.2: Anexo B: Análise Descritiva

```

# --- Pacotes ---
library("dplyr")

# Carrega os dados filtrados de Santa Catarina
source(file = "script_sc.r")

# --- Filtrando os dados ---

# ENADE
dados_enade <- data_CPC_SC %>%
  select(conceito_enade_.continuo.) %>%
  filter(!is.na(conceito_enade_.continuo.))

# CPC
dados_cpc <- data_CPC_SC %>%
  select(cpc_.continuo.) %>%
  filter(!is.na(cpc_.continuo.))

# IDD
dados_idd <- data_IDD_SC %>%
  select(idd_.continuo.) %>%
  filter(!is.na(idd_.continuo.))

```

```

# IGC
dados_igc <- data_IGC_SC %>%
  select(igc_.continuo.) %>%
  filter(!is.na(igc_.continuo.))

# Modalidade de Ensino
dados_me <- data_CPC_SC %>%
  select(modalidade_de_ensino) %>%
  filter(!is.na(modalidade_de_ensino))

# Categoria Administrativa
dados_ca <- data_IGC_SC %>%
  select(categoria_administrativa) %>%
  filter(!is.na(categoria_administrativa))

# --- Criar amostra aleatória de tamanho n = 426, conforme "amostragem.r" ---
# ENADE
set.seed(123) # para reproduzibilidade
amostra_enade <- dados_enade %>%
  sample_n(size = 699, replace = FALSE)

#CPC
set.seed(123) # para reproduzibilidade
amostra_cpc <- dados_cpc %>%
  sample_n(size = 426, replace = FALSE)

# IDD
set.seed(123) # para reproduzibilidade
amostra_idd <- dados_idd %>%
  sample_n(size = 707, replace = FALSE)

# IGC
set.seed(123) # para reproduzibilidade
amostra_igc <- dados_igc %>%
  sample_n(size = 163, replace = FALSE)

# Modalidade de Ensino
set.seed(123) # para reproduzibilidade
amostra_me <- dados_me %>%
  sample_n(size = 300, replace = FALSE)

# Categoria Administrativa

```

```

set.seed(123) # para reproduzibilidade
amostra_ca <- dados_ca %>%
  sample_n(size = 150, replace = FALSE)

# --- Estatísticas Descritivas ---

# ENADE
media_enade <- mean(amostra_enade$conceito_enade_.continuo.)
mediana_enade <- median(amostra_enade$conceito_enade_.continuo.)
dp_enade <- sd(amostra_enade$conceito_enade_.continuo.)
erro_enade = qt((1+0.95)/2, 699-1) * (dp_enade/(sqrt(699)))

cat("Média Conceito Enade:", round(media_enade, 4), "\n")
cat("Mediana Conceito Enade:", round(mediana_enade, 4), "\n")
cat("Desvio Padrão Conceito Enade:", round(dp_enade, 4), "\n")
cat("Intervalo de Confiança da Média do Conceito Enade:", round(media_enade-
  erro_enade, 4), "-", round(media_enade+erro_enade, 4), "\n")

# CPC
media_cpc <- mean(amostra_cpc$cpc_.continuo.)
mediana_cpc <- median(amostra_cpc$cpc_.continuo.)
dp_cpc <- sd(amostra_cpc$cpc_.continuo.)
erro_cpc = qt((1+0.95)/2, 426-1) * (dp_cpc/(sqrt(426)))

cat("Média CPC:", round(media_cpc, 4), "\n")
cat("Mediana CPC:", round(mediana_cpc, 4), "\n")
cat("Desvio Padrão CPC:", round(dp_cpc, 4), "\n")
cat("Intervalo de Confiança da Média do CPC:", round(media_cpc-erro_cpc, 4),
  "-", round(media_cpc+erro_cpc, 4), "\n")

# IDD
media_idd <- mean(amostra_idd$idd_.continuo.)
mediana_idd <- median(amostra_idd$idd_.continuo.)
dp_idd <- sd(amostra_idd$idd_.continuo.)
erro_idd = qt((1+0.95)/2, 707-1) * (dp_idd/(sqrt(707)))

cat("Média IDD:", round(media_idd, 4), "\n")
cat("Mediana IDD:", round(mediana_idd, 4), "\n")
cat("Desvio Padrão IDD:", round(dp_idd, 4), "\n")
cat("Intervalo de Confiança da Média do IDD:", round(media_idd-erro_idd, 4),
  "-", round(media_idd+erro_idd, 4), "\n")

# IGC

```

```

media_igc <- mean(amostra_igc$igc_.continuo.)
mediana_igc <- median(amostra_igc$igc_.continuo.)
dp_igc <- sd(amostra_igc$igc_.continuo.)
erro_igc = qt((1+0.95)/2, 163-1) * (dp_igc/(sqrt(163)))

cat("Média IGC:", round(media_igc, 4), "\n")
cat("Mediana IGC:", round(mediana_igc, 4), "\n")
cat("Desvio Padrão IGC:", round(dp_igc, 4), "\n")
cat("Intervalo de Confiança da Média do IGC:", round(media_igc-erro_igc, 4),
    "-", round(media_igc+erro_igc, 4), "\n")

# Modalidade de ensino
presencial <- sum(amostra_me$modalidade_de_ensino == "Educação Presencial")
total <- nrow(amostra_me)
prop_me <- (presencial / total)
erro_me <- qnorm((1+0.95)/2)*(sqrt(prop_me*(1-prop_me)/300))

cat("Proporção de Cursos Presenciais:", round(prop_me*100, 4), "\n")
cat("Intervalo de Confiança da Proporção de Cursos Presenciais:", round((
    prop_me-erro_me)*100, 4), "-", round((prop_me+erro_me)*100, 4), "\n")

# Categoria Adiministrativa
publicas <- sum(amostra_ca$categoria_administrativa == "Pública Federal",
    amostra_ca$categoria_administrativa == "Pública Estadual",
    amostra_ca$categoria_administrativa == "Pública Munucipal")
total <- nrow(amostra_ca)
prop_ca <- (publicas / total)
erro_ca <- qnorm((1+0.95)/2)*(sqrt(prop_ca*(1-prop_ca)/150))

cat("Proporção de Instituições Públicas:", round(prop_ca*100, 4), "\n")
cat("Intervalo de Confiança da Proporção de Instituições Públicas:", round((
    prop_ca-erro_ca)*100, 4), "-", round((prop_ca+erro_ca)*100, 4), "\n")

```

Listing 5.3: Anexo C: Hipótese sobre a Média

```

setwd("~/Documents/ENADE-Estatisticas")

# --- Pacotes ---
library(dplyr)
library(ggplot2)

# --- Filtrando os dados ---
dados_modalidade <- data_CPC_SC %>%

```

```

filter(modalidade_de_ensino %in% c("Educação Presencial", "Educação a Distâ-
ncia")) %>%
select(modalidade_de_ensino, cpc_.continuo.) %>%
filter(!is.na(cpc_.continuo.))

# --- Criar amostra aleatória de tamanho n = 426, conforme "amostragem.r" ---
set.seed(123) # para reproduzibilidade
dados_amostra <- dados_modalidade %>%
  sample_n(size = 426, replace = FALSE)

# --- Separando os grupos ---
presencial <- dados_amostra %>%
  filter(modalidade_de_ensino == "Educação Presencial") %>%
  pull(cpc_.continuo.)

ead <- dados_amostra %>%
  filter(modalidade_de_ensino == "Educação a Distância") %>%
  pull(cpc_.continuo.)

# --- Teste t de Welch ---
teste_t <- t.test(presencial, ead,
                    alternative = "greater", # teste unilateral à direita
                    var.equal = FALSE) # Welch (variâncias diferentes)

# --- Exibir resultado ---
print(teste_t)

# --- Boxplot comparativo ---
dev.new()
pdf("boxplot_modalidade.pdf", width = 7, height = 5)
print(
  ggplot(dados_amostra, aes(x = modalidade_de_ensino, y = cpc_.continuo., fill =
    modalidade_de_ensino)) +
  geom_boxplot(alpha = 0.7) +
  stat_summary(fun = mean, geom = "point", shape = 23, size = 3, fill = "white
    ") +
  labs(x = "Modalidade de Ensino",
       y = "CPC (Contínuo)") +
  theme_minimal() +
  theme(legend.position = "none")
)
dev.off()

```

Listing 5.4: Anexo D: Hipótese sobre a Proporção

```
setwd("~/Documents/ENADE-Estísticas")
source(file = "src/script_sc.r")

# --- Pacotes ---
library(dplyr)

# --- Amostra aleatória de instituições ---
set.seed(123)
amostra_n <- 150
amostra_instituicoes <- data_IGC_SC %>%
  sample_n(amostra_n)

# --- Contagem de instituições federais ---
sucesso <- sum(amostra_instituicoes$categoria_administrativa == "Pública
  Federal")
total <- nrow(amostra_instituicoes)
prop_observada <- sucesso / total

cat("Tamanho da amostra:", total, "\n")
cat("Número de instituições federais na amostra:", sucesso, "\n")
cat("Proporção observada:", round(prop_observada, 3), "\n\n")

# --- Teste de hipótese para proporção única (bilateral) ---
# H0: p = 0.25
# H1: p != 0.25
teste_prop <- prop.test(x = sucesso, n = total, p = 0.25, alternative = "two.
  sided", correct = FALSE)
print(teste_prop)

# --- Interpretação ---
cat("\nInterpretação:\n")
if (teste_prop$p.value < 0.05) {
  cat("Rejeita-se H0: A proporção de instituições federais é significativamente
    diferente de 25%.\n")
} else {
  cat("Não se rejeita H0: Não há evidências de que a proporção de instituições
    federais seja diferente de 25%.\n")
}

# --- Gráfico do teste bilateral e salvamento em PDF ---
p0 <- 0.25
phat <- prop_observada
```

```

n <- total
z <- (phat - p0) / sqrt(p0 * (1 - p0) / n)
print(z)
alpha <- 0.05
zcrit <- qnorm(1 - alpha / 2)
print(zcrit)

# Caminho de saída
pdf("teste_bilateral.pdf", width = 10, height = 5)

# Dados da distribuição normal padrão
x <- seq(-6, 6, length = 1000)
y <- dnorm(x)

# Plot principal
plot(x, y, type = "l", lwd = 2, col = "black",
      main = "Teste Bilateral para Proporção",
      xlab = "Estatística Z", ylab = "Densidade de probabilidade")

# Regiões críticas
polygon(c(x[x >= zcrit], rev(x[x >= zcrit])),
         c(y[x >= zcrit], rep(0, sum(x >= zcrit))), 
         col = rgb(1, 0, 0, 0.4), border = NA)
polygon(c(x[x <= -zcrit], rev(x[x <= -zcrit])),
         c(y[x <= -zcrit], rep(0, sum(x <= -zcrit))), 
         col = rgb(1, 0, 0, 0.4), border = NA)

# Linha do valor observado
abline(v = z, col = "blue", lwd = 2)
abline(v = c(-zcrit, zcrit), col = "red", lty = 2)

# Legenda e texto
legend("topright",
       legend = c("Z observado", "Regiões críticas (alpha = 0.05)"),
       col = c("blue", "red"), lwd = 2, lty = c(1, 2), bty = "n")

text(z, dnorm(z) + 0.02, labels = sprintf("z = %.2f", z),
     col = "blue", pos = ifelse(z < 0, 2, 4))

dev.off()

```

Listing 5.5: Anexo E: Hipótese sobre a Correlação e Regressão

```
# Diretório da base de dados - Talvez precisa alterar, dependendo de onde o
# repositório estiver clonado.
setwd("~/Documents/ENADE-Estatisticas")

# ---- Filtragem das tabelas ----

# Retira eventuais entradas nulas
data_CPC_SC_limpo <- na.omit(data_CPC_SC[, c("ano", "codigo_da_ies", "
  nome_da_ies", "codigo_do_curso", "area_de_avaliacao", "conceito_enade_.
  continuo.")])
data_IDD_SC_limpo <- na.omit(data_IDD_SC[, c("ano", "codigo_da_ies", "
  nome_da_ies", "codigo_do_curso", "area_de_avaliacao", "idd_.continuo.")])

# Faz a amostragem de acordo com os valores de n calculados em "amostragem.r"
# Note que as amostras são independentes
set.seed(123)
amostra_CPC <- data_CPC_SC_limpo[sample(1:nrow(data_CPC_SC_limpo), 699, replace
  = FALSE), ]
rownames(amostra_CPC) <- NULL
amostra_IDD <- data_IDD_SC_limpo[sample(1:nrow(data_IDD_SC_limpo), 707, replace
  = FALSE), ]
rownames(amostra_IDD) <- NULL

# Faz o merge das tabelas pelas colunas-chave
data_merged <- merge(
  x = amostra_CPC,
  y = amostra_IDD,
  by = c("ano", "codigo_da_ies", "codigo_do_curso"),
  suffixes = c("_CPC", "_IDD"))
)

# Seleciona as colunas principais para análise
data_corre_reg <- data.frame(
  ano = data_merged$ano,
  codigo_da_ies = data_merged$codigo_da_ies,
  codigo_do_curso = data_merged$codigo_do_curso,
  nome_da_ies = data_merged$nome_da_ies_CPC,
  nome_do_curso = data_merged$area_de_avaliacao_CPC,
  conceito_enade = data_merged$conceito_enade_.continuo.,
  idd = data_merged$idd_.continuo.
)
```

```

# Remove linhas com valores faltantes (NA) em Enade ou IDD
data_corre_reg <- subset(data_corre_reg, !is.na(conceito_enade) & !is.na(idd))
rownames(data_corre_reg) <- NULL

# ---- Teste de hipótese sobre correlação ----

# Teste de correlação entre ENADE e IDD
cor.test(data_corre_reg$conceito_enade, data_corre_reg$idd, method = "pearson")

# ---- Teste de hipótese sobre regressão ----

# Modelo de regressão linear (ENADE dependente de IDD)
modelo <- lm(conceito_enade ~ idd, data = data_corre_reg)

# Sumário com teste t dos coeficientes
summary(modelo)

# Gráfico da Relação ENADE e IDD contínuos
dev.new()
plot(data_corre_reg$idd, data_corre_reg$conceito_enade,
      xlab = "IDD", ylab = "Conceito ENADE",
      main = "Relação linear entre IDD e ENADE",
      pch = 19, col = "blue")

#Plot da Linha de regressão
abline(modelo, col = "red", lwd = 2)

```